向量检索评估方法说明

本文说明检索系统的离线评估口径。评估以查询为粒度，
关注三个指标：命中率、首条命中率与平均倒数排名。

一、指标定义

命中率指检索结果的前若干条中是否出现目标片段，只要出现即算命中。
首条命中率要求目标片段排在第一位，比命中率更严格。
平均倒数排名对每个查询取目标片段排名的倒数再求平均，
排名越靠前得分越高，排名靠后时该值迅速衰减。

二、零字面重叠的困难样本

评估集中必须包含与目标片段没有任何连续字面重合的查询。
这类样本用于暴露纯粹的词面匹配缺陷：当查询与文档用词完全不同时，
只有理解语义才能召回正确片段。
若系统在此类样本上大面积失效，说明向量表示不具备语义能力，
应更换嵌入模型而不是继续调整融合权重。

三、结论口径

报告评估结果时必须同时给出样本量。样本过少时单个样本的
波动会显著改变整体指标，不足以支撑质量结论。